

TRABALHO DE PESQUISA AV1
BUSCA HEURÍSTICA, BUSCA LOCAL
E ÁRVORE DE DECISÃO
INTELIGÊNCIA ARTIFICIAL E COMPUTACIONAL (0700M8)

Prof. Daniel Leal Souza – Semestre: 01/2026

Disciplina	Inteligência Artificial e Computacional (0700M8)
Professor	Daniel Leal Souza
Tema	Modelagem, implementação, análise experimental, documentação técnica e apresentação oral ao vivo de algoritmos de busca heurística ou busca local, além de árvores de decisão
Conteúdos	Busca pela Melhor Escolha (BestFS), Busca Gulosa, A*, heurísticas (admissibilidade, consistência e construção de funções heurísticas), Hill Climbing, Simulated Annealing, máximos locais, platôs, estratégias de melhoria, árvores de decisão, ID3/C4.5/CART, entropia, ganho de informação, validação, poda e interpretação de modelos
Formato	Trabalho em equipes de até 4 integrantes, com apresentação oral obrigatória ao vivo via Google Meet
Ferramentas	Linguagem de programação livre; recomenda-se Google Colab, Python, Orange, scikit-learn ou ambiente equivalente
Entrega	Relatório técnico em PDF + código-fonte + evidências de execução + anexos com árvores, tabelas, gráficos e capturas de tela + apresentação oral ao vivo via Google Meet
Prazo (CC5MA e CC5NA)	11/04/2026: apresentação obrigatória ao vivo via Google Meet (entre 08h30 e 11h30, conforme ordem definida pelo professor) e submissão final dos arquivos até 23h59, via Google Classroom
Pontuação	Até 4.0 pts
Número de Integrantes por Equipe	Até QUATRO alunos por equipe

Introdução

Esta atividade foi organizada para consolidar conteúdos do primeiro bimestre, com ênfase em **busca heurística**, **busca local** e **árvores de decisão**, seguindo a abordagem prática da disciplina em laboratório, com uso de **Colab** e/ou **Orange**, documentação técnica, validação experimental e apresentação oral ao vivo.

Síntese conceitual para orientação

- **Busca heurística:** utiliza conhecimento adicional do problema para orientar a expansão dos nós, por meio de uma função heurística $h(n)$ que estima o custo do estado atual até o objetivo.
- **Busca pela Melhor Escolha (BestFS):** classe geral de algoritmos que seleciona, na fronteira, o nó com melhor avaliação segundo uma função $f(n)$.
- **Busca Gulosa:** considera apenas a estimativa heurística, isto é, $f(n) = h(n)$. Pode ser rápida, mas não é garantidamente ótima.
- **A*:** combina custo acumulado e heurística, por meio de $f(n) = g(n) + h(n)$. Com heurística admissível, é completa e ótima em condições clássicas.
- **Admissibilidade e consistência:** uma heurística admissível não superestima o custo real até a meta; uma heurística consistente respeita a monotonicidade ao longo do caminho.
- **Busca local:** trabalha com um estado corrente e busca melhorar uma função objetivo sem, necessariamente, registrar toda a árvore de busca.
- **Hill Climbing:** avança para vizinhos melhores; pode ficar preso em máximos locais, planícies e cristas.
- **Simulated Annealing:** permite, com certa probabilidade, movimentos para estados piores no início do processo, reduzindo essa probabilidade com o tempo por meio de uma política de resfriamento.
- **Árvores de decisão:** modelos interpretáveis que particionam o espaço de atributos por testes sucessivos, gerando regras de decisão até folhas de classificação ou regressão.
- **Crítérios de divisão:** a escolha do atributo pode ser guiada por entropia, ganho de informação, índice Gini ou critérios equivalentes, dependendo do algoritmo utilizado.
- **Validação e poda:** são essenciais para evitar sobreajuste (overfitting), controlar a complexidade da árvore e melhorar a generalização.

Finalidade da atividade

Esta atividade foi elaborada para desenvolver competências de **modelagem de problemas**, **implementação algorítmica**, **análise comparativa** e **interpretação de resultados** em duas frentes obrigatórias da disciplina:

1. **Árvores de Busca:** os alunos deverão escolher **exatamente uma** das duas categorias abaixo e executar as instruções correspondentes:
 1. **OPÇÃO A: Busca heurística**, com foco em formulação de estados, construção e comparação de heurísticas, desempenho de Busca Gulosa e A*, e interpretação de listas aberta/fechada, custo e ordem de expansão;

2. **OPÇÃO B: Busca local**, com foco em otimização, definição de função objetivo, análise de topologia do espaço de estados, comportamento do Hill Climbing e do Simulated Annealing, além de mecanismos para escapar de máximos locais e platôs.
2. **Árvores de decisão**, com foco em aprendizagem interpretável, critério de partição, validação, poda, interpretação do modelo e análise de desempenho em dados reais ou simulados.

Instruções gerais

- O trabalho deverá ser desenvolvido em **equipes de até 4 integrantes**.
- A equipe deverá desenvolver um projeto com **duas partes obrigatórias**:
 1. escolher **uma** entre as opções de árvores de busca:
 - a) **OPÇÃO A: Busca Heurística**; ou
 - b) **OPÇÃO B: Busca Local**;
 2. desenvolver, obrigatoriamente, a parte de **Árvores de Decisão**.
- O relatório deve ser **técnico, claro e reproduzível**, descrevendo o problema, a modelagem, os algoritmos, os parâmetros, os testes, os resultados e as limitações observadas.
- Toda implementação deve conter evidências concretas de execução: **prints, logs, tabelas, gráficos, saídas do programa** ou visualizações equivalentes.
- Toda hipótese adicional adotada deverá ser declarada explicitamente. Exemplos: política de desempate, ordem dos vizinhos, estrutura de dados, critérios de parada, número de iterações, sementes aleatórias, esquema de resfriamento, profundidade máxima de árvore, validação cruzada etc.
- **Todo conteúdo gerado por IA deverá ser documentado**. Caso a equipe use IA para produzir código, explicações, textos, imagens, fluxogramas, roteiro da apresentação ou análise, deverá registrar ferramenta, prompt resumido, trecho aproveitado e revisão crítica realizada.
- O trabalho deve demonstrar **entendimento conceitual**. Não basta executar bibliotecas; a equipe deverá explicar como e por que o algoritmo funciona, quais parâmetros foram escolhidos e quais resultados foram observados.
- Sempre que possível, a equipe deverá apresentar elementos de **visualização e interpretabilidade**. Isso vale tanto para busca (mapa, percurso, custos, expansão, gráfico da função objetivo) quanto para árvore de decisão (diagrama, regras, atributos, métricas).
- **A apresentação do trabalho será realizada ao vivo via Google Meet**, na data indicada nesta lauda. Essa apresentação é parte obrigatória da avaliação.
- **Não haverá entrega de vídeo gravado**. A demonstração do trabalho será feita exclusivamente na apresentação oral síncrona via Google Meet.

Sobre a Implementação dos Algoritmos

Desenvolva a solução utilizando as técnicas de IA selecionadas. Cada algoritmo deve ser funcional e adequado ao problema definido, respeitando os requisitos específicos mínimos listados adiante para cada categoria. A implementação pode ser feita utilizando bibliotecas ou ferramentas de escolha da equipe (ex.: MATLAB, scikit-learn em Python, Unity, Blender, PyOpenGL, PyGame etc.).

Opção A: Busca Heurística

Nesta parte, a equipe deverá modelar um problema de busca em espaço de estados e implementar algoritmos de **busca heurística**.

Escopo obrigatório

- Explicar brevemente o papel da **Busca pela Melhor Escolha (BestFS)** como classe geral de estratégias informadas.
- Implementar, obrigatoriamente, a **Busca Gulosa** e o algoritmo A^* .
- Utilizar um cenário com estado inicial, objetivo, ações válidas e custo de caminho bem definidos. Exemplos: mapa ponderado, labirinto, quebra-cabeça de 8 peças, problema de rota, jogo TERMO modelado como busca, entre outros.
- Definir e justificar **ao menos duas heurísticas** para o mesmo problema, sendo desejável que a equipe compare uma heurística mais fraca com outra mais informativa.

O que a equipe deve entregar?

1. Descrição formal do problema: estado inicial, ações, teste de objetivo, função custo e representação do espaço de estados. O grupo deverá implementar um programa que utilize ambas as buscas, sendo o problema escolhido a critério da equipe.
2. Explicação da função heurística $h(n)$ utilizada em cada experimento.
3. Discussão explícita sobre **admissibilidade** e **coerência** da heurística. A equipe deve mostrar que a heurística usada é aplicável ao problema tratado.
4. Implementação e execução de:
 - Busca Gulosa e uma variante (ex. GRASP, GSAT / WalkSAT);
 - Busca A^* e uma variante (ex. IDA, WA);
 - comparação entre pelo menos duas heurísticas diferentes no mesmo problema.
5. Apresentação da **árvore de busca**, da ordem de expansão ou de uma visualização equivalente da exploração do espaço de estados. Para a árvore de busca, não é necessário o uso de árvores muito grandes, mas apenas que prove que o programa implementado está utilizando os algoritmos de busca heurística corretamente.
6. Registro, para cada cenário testado, de:
 - caminho encontrado;
 - custo final;
 - número de nós expandidos;
 - interpretação dos valores de $g(n)$, $h(n)$ e $f(n)$ em nós relevantes;
 - observações sobre tempo e memória.
7. Discussão sobre como a qualidade da heurística afeta o desempenho do algoritmo.
8. Comentário sobre como a heurística foi construída. Pesquise e aplique dois dos métodos de construção de heurísticas a seguir: **relaxamento de restrições**, **informação estatística**, **combinação de heurísticas**, **distância Manhattan**, **distância Euclidiana** ou **função heurística composta**.

Opção B: Busca Local

Nesta parte, a equipe deverá modelar um problema de **otimização** e implementar algoritmos de busca local.

Escopo obrigatório

- Implementar **Hill Climbing** e **Simulated Annealing**.
- Explicar a **função objetivo** utilizada e a vizinhança do problema.
- Pesquisar na literatura científica, discutir e implementar **uma estratégia de melhoria para Hill Climbing e Simulated Annealing**, entre as opções (mas não restrito a elas):
 - **Hill Climbing**: Máxima Inclinação, Estocástico, Com Reinício Aleatório, Análise de Níveis Adiante, Parada no Platô.
 - **Simulated Annealing**: Diferentes esquemas de Resfriamento, Simulated Annealing Híbrido (com Hill Climbing).

Sugestões de problemas

A equipe pode escolher, entre outros, problemas como: 8 rainhas, caixeiro viajante, alocação de horários, ajuste de parâmetros, múltiplas mochilas, função matemática de otimização, arranjo de salas ou outra formulação adequada.

O que a equipe deve entregar?

1. Formulação do problema de otimização, incluindo representação do estado, função objetivo, critérios de vizinhança e critério de parada.
2. Implementação do **Hill Climbing** e do **Simulated Annealing**.
3. Implementação de pelo menos **uma melhoria prática** para o Hill Climbing e para o Simulated Annealing. O uso de versões modificadas e/ou híbridas dos algoritmos é obrigatório.
4. Registro e discussão de fenômenos clássicos de busca local, quando aparecerem: **máximos locais, mínimos locais, platôs, cristas** ou forte dependência do estado inicial.
5. Para o Simulated Annealing, descrição do padrão de temperatura, da função objetivo e do critério de resfriamento. Apresente um esquema de temperatura e explique seu uso no programa.
6. Visualização do processo de busca, por exemplo:
 - gráfico do valor da função objetivo por iteração;
 - gráfico da temperatura ao longo do tempo;
 - tabela resumo de execuções.
7. Comparação experimental entre os algoritmos e discussão dos resultados obtidos.
8. Quando houver aleatoriedade, realizar múltiplas execuções e apresentar estatísticas mínimas, como média, melhor caso, pior caso ou taxa de sucesso.

Parte obrigatória: Árvores de Decisão

Nesta parte, a equipe deverá aplicar **árvores de decisão** em um problema de classificação ou regressão.

Escopo obrigatório

- Escolher um conjunto de dados real ou sintético, com quantidade razoável de instâncias e múltiplos atributos.
- Implementar uma árvore de decisão por um dos caminhos abaixo:
 - implementação própria inspirada em ID3/C4.5; ou
 - uso de biblioteca como scikit-learn (programação) ou Orange (programação visual), desde que a equipe compreenda o funcionamento interno dos métodos e dos algoritmos.
- Discutir critérios de partição, validação e poda.

O que a equipe deve entregar nesta Parte

1. Descrição do dataset: origem, atributos, variável-alvo e eventual pré-processamento.
2. Indicação do critério de divisão utilizado: entropia/ganho de informação, índice Gini ou outro critério compatível com o algoritmo escolhido.
3. Explicação conceitual do processo de construção da árvore, incluindo:
 - escolha do atributo da raiz;
 - partições recursivas;
 - condições de parada;
 - relação entre pureza, entropia e ganho de informação.
4. Treinamento, validação e teste do modelo, com evidências experimentais. Pode-se usar hold-out, validação cruzada ou procedimento equivalente.
5. Comparação entre pelo menos **duas configurações** da árvore. Exemplos: com poda e sem poda; profundidades diferentes; entropia versus Gini; árvore rasa versus árvore profunda.
6. Discussão de **overfitting** e do papel da **poda** e da **validação** para controle da complexidade.
7. Apresentação visual da árvore gerada ou de um conjunto de regras equivalente.
8. Interpretação do modelo: quais atributos apareceram mais próximos da raiz, que regras relevantes foram produzidas e o que a árvore sugere sobre os dados.
9. Caso haja atributos contínuos, explicar como o algoritmo lidou com limiares de divisão.

Entregáveis obrigatórios

A entrega da equipe deverá conter, no mínimo, os itens abaixo:

1. **Código-fonte completo**, comentado e organizado.
2. **Relatório técnico em PDF**, preferencialmente entre 6 e 10 páginas, com escrita acadêmica clara.
3. **Apresentação oral obrigatória ao vivo via Google Meet**, com demonstração do funcionamento do trabalho e breve arguição.
4. **Evidências de execução**: prints, logs, tabelas, gráficos, saídas do programa ou visualizações equivalentes.
5. **Árvores de busca / diagramas / visualizações** usados na parte escolhida entre OPÇÃO A e OPÇÃO B.
6. **Gráficos, tabelas ou registros experimentais de desempenho** usados na parte escolhida entre OPÇÃO A e OPÇÃO B.
7. **Visualização da árvore de decisão** e métricas experimentais usadas na parte de Árvores de Decisão.
8. **Anexo de uso de IA**, quando houver.

Estrutura sugerida para o relatório

1. Introdução e objetivo do trabalho;
2. Ferramentas utilizadas e organização da equipe;
3. Parte 1: OPÇÃO A (Busca Heurística) **ou** OPÇÃO B (Busca Local);
4. Parte 2: Árvores de Decisão;
5. Comparação global e discussão integrada;
6. Limitações, dificuldades e possibilidades de melhoria;
7. Conclusão;
8. Referências e anexos.

Resumo do trabalho

Este trabalho possui **duas partes obrigatórias**. Na primeira, a equipe deverá escolher **uma** entre as seguintes opções: **OPÇÃO A — Busca Heurística** ou **OPÇÃO B — Busca Local**. Na segunda, a equipe deverá obrigatoriamente desenvolver a parte de **Árvores de Decisão**. Em ambos os casos, espera-se modelagem correta do problema, implementação funcional, análise experimental, produção de evidências de execução e discussão técnica dos resultados.

A entrega final será composta por **relatório técnico em PDF**, **código-fonte**, **evidências experimentais** e anexos pertinentes. Além disso, a equipe deverá realizar uma **apresentação oral ao vivo via Google Meet**, na qual demonstrará o funcionamento do trabalho e responderá à arguição do professor. **Não haverá entrega de vídeo gravado**: a apresentação será exclusivamente síncrona, na data e no horário informados nesta lauda.

Regras, Rubrica e Penalidades (Pontuação: 0–100)

A avaliação considerará a qualidade da modelagem, da implementação, da validação experimental, da análise dos resultados, da clareza do relatório e da apresentação oral.

Observação: a rubrica abaixo é expressa em escala de 0 a 100 e será convertida proporcionalmente para a nota da atividade (até 4,0 pontos).

Critério	Peso	Detalhes de Avaliação
1. Modelagem e implementação da parte escolhida	20 pts	A equipe deverá escolher uma das duas opções: (a) OPÇÃO A — Busca Heurística , com formulação correta do problema, implementação da Busca Gulosa e do A*, definição das heurísticas, análise de admissibilidade/consistência e comparação experimental; ou (b) OPÇÃO B — Busca Local , com formulação da função objetivo, implementação de Hill Climbing e Simulated Annealing, estratégias de melhoria, análise de máximos locais, platôs e dos experimentos.
2. Modelagem e aplicação de Árvores de Decisão	20 pts	Escolha adequada do dataset, critério de partição, validação, poda, interpretação da árvore, análise de overfitting e clareza dos resultados.
3. Validação experimental e comparação dos resultados	30 pts	Existência de testes, casos comparativos, métricas relevantes, coerência entre parâmetros e conclusões, além de discussão crítica das limitações.
4. Documentação, organização e integridade acadêmica	10 pts	Clareza do relatório, reprodutibilidade, organização da entrega, legibilidade de figuras/tabelas e documentação do uso de IA.
5. Apresentação do trabalho (Google Meet)	20 pts	Participação dos integrantes, demonstração funcional do programa, clareza, objetividade, domínio conceitual, capacidade de resposta à arguição e qualidade da comunicação técnica durante a apresentação ao vivo.

Penalidades:

- **Ausência de uma parte obrigatória:** até -20 pontos por parte ausente. Consideram-se obrigatórias: **(i)** a parte escolhida entre OPÇÃO A e OPÇÃO B; e **(ii)** a parte de Árvores de Decisão.
- **Implementação incompatível com o algoritmo declarado:** até -10 pontos por ocorrência.
- **Ausência de evidências de execução:** até -10 pontos.
- **Heurística sem definição ou sem justificativa:** até -10 pontos na OPÇÃO A.
- **Ausência de discussão sobre máximos locais, platôs, temperatura ou critérios de melhoria:** até -10 pontos na OPÇÃO B.
- **Ausência de validação ou poda na parte de Árvores de Decisão:** até -10 pontos.
- **Uso de IA sem documentação:** -10 pontos.
- **Ausência da apresentação ao vivo via Google Meet:** nota 0 (zero) no Critério 5.
- **Plágio, cópia ou reprodução indevida sem autoria declarada:** nota 0 (zero) para a equipe, conforme as normas da disciplina.

Serão particularmente valorizados os trabalhos que demonstrarem **compreensão conceitual, boa modelagem, testes bem conduzidos, capacidade de interpretação dos resultados e uso adequado das ferramentas da disciplina**. Trabalhos que apenas executem bibliotecas sem discussão técnica consistente não alcançarão a pontuação máxima.

Prazo de entrega e apresentação

- **Turmas CC5MA e CC5NA:** a apresentação do trabalho será realizada **exclusivamente ao vivo via Google Meet** no dia **11/04/2026**, entre **08h30 e 11h30**, conforme ordem de apresentação definida pelo professor.
- A **submissão final dos arquivos** (relatório em PDF, código-fonte, evidências e anexos) deverá ser realizada até **23h59 do mesmo dia**, via **Google Classroom**.

IMPORTANTE: Não haverá extensão prazo ou de horário da apresentação.

Checklist geral

- ☐ Equipe formada e ferramentas definidas.
- ☐ Escolha realizada entre **OPÇÃO A** (Busca Heurística) e **OPÇÃO B** (Busca Local).
- ☐ Parte de **Árvores de Decisão** definida.
- ☐ Relatório técnico em elaboração.
- ☐ Evidências experimentais organizadas.
- ☐ Uso de IA documentado, quando houver.
- ☐ Materiais preparados para submissão no Google Classroom.
- ☐ Apresentação preparada para o Google Meet.

Checklist: OPÇÃO A: Busca Heurística

- ☐ Problema modelado em espaço de estados.
- ☐ Busca Gulosa e A* implementados.
- ☐ Duas heurísticas definidas e justificadas.
- ☐ Comparação experimental realizada.
- ☐ Árvore de busca ou visualização equivalente incluída.

Checklist: OPÇÃO B: Busca Local

- ☐ Problema de otimização modelado.
- ☐ Hill Climbing e Simulated Annealing implementados.
- ☐ Função objetivo, vizinhança e melhoria definidos.
- ☐ Comparação experimental realizada.
- ☐ Visualizações e análise dos resultados incluídas.

Checklist: Árvores de Decisão

- ☐ Dataset escolhido e descrito.
- ☐ Árvore implementada e validada.
- ☐ Critério de divisão, poda e overfitting discutidos.
- ☐ Comparação entre configurações realizada.
- ☐ Árvore ou regras interpretadas e apresentadas.